

SHIPPINGBO

Cas Pratique — Ingénieur Produit IA

Évaluation de la qualité d'un agent IA de support e-commerce

Durée : 48h · Livrables : code + document · Débrief en entretien : 30 min

1. CONTEXTE

Shippingbo est une plateforme SaaS de gestion des expéditions utilisée par des milliers de marchands e-commerce en France et en Europe. Pour ce cas pratique, nous vous demandons de travailler sur **ShipEasy** — une version fictive et simplifiée d'une telle plateforme — afin de préserver la confidentialité de nos données réelles.

ShipEasy propose aux marchands une interface de gestion des expéditions avec connecteurs transporteurs (Colissimo, Chronopost, DPD, Mondial Relay...), gestion des règles d'expédition automatiques, tracking unifié et tableau de bord analytique. Un **agent IA conversationnel** est intégré à l'interface pour répondre aux questions des marchands sur leurs commandes, l'utilisation du logiciel et les transporteurs disponibles.

2. VOTRE MISSION

Votre mission comporte deux volets complémentaires : une partie technique et une partie produit.

Partie A — Analyse et évaluation technique

1. Identifiez les conversations où l'agent a fourni une réponse incorrecte, incomplète ou inappropriée. Expliquez votre méthode de détection.
2. Implémentez un script Python qui calcule au minimum 2 métriques de qualité de votre choix sur ce dataset. Justifiez vos choix de métriques.
3. Construisez un golden dataset minimal de 5 paires question/réponse de référence, que vous utiliseriez pour benchmarker cet agent en continu.

Partie B — Recommandations produit

4. Sur la base de votre analyse, identifiez les 3 problèmes les plus critiques rencontrés par l'agent.
5. Pour chaque problème : décrivez le défaut observé, proposez une solution concrète, et définissez comment vous mesureriez l'amélioration.

Liberté méthodologique

Il n'y a pas une seule bonne approche. Vous pouvez utiliser un framework existant (RAGAS, DeepEval...), implémenter vos propres métriques, ou combiner les deux. Ce qui compte : la clarté de votre raisonnement et la pertinence de vos choix par rapport au contexte.

3. LIVRABLES ATTENDUS

Vous devrez remettre deux livrables :

Livrable	Contenu	Format
Code	Script(s) d'évaluation commentés, golden dataset inclus. Un README expliquant comment exécuter le code.	Repo Git (GitHub/GitLab) ou archive .zip
Document de synthèse	Analyse des messages du jeu de données, analyse des défauts identifiés, metriquess, justification des métriques choisies, 3 recommandations produit structurées.	PDF ou slides — 2 pages max ou 5 slides max

Critère de qualité avant tout

Un code clair et bien documenté sur 50 lignes vaut mieux qu'un code complexe illisible. Idem pour le document : soyez concis et structuré.

Bonne chance !

L'équipe Shippingbo est impatiente de découvrir votre approche.